

Министерство науки и высшего образования Российской Федерации
федеральное государственное автономное образовательное учреждение
высшего образования
«Национальный исследовательский университет ИТМО»

Факультет программной инженерии и компьютерной техники

Лабораторная работа №1

По дисциплине "Основы машинного обучения" на тему
"Работа с данными. Очистка и отбор признаков"

Группа: Р3324

Выполнил: Пахомов Владислав
Владимирович

Проверил:

к.т.н. доцент Фамилия И.О.

Санкт-Петербург

2026

ОГЛАВЛЕНИЕ

Оглавление будет сформировано автоматически при обновлении поля (ПКМ → «Обновить поле»)

ВВЕДЕНИЕ

Цель работы: провести очистку набора скважинных измерений и отобрать набор признаков, информативных для последующего предсказания целевых переменных G_total (массовый дебит) и КГФ (газоконденсатный фактор).

Источник данных: ID_data_mass_18122012, лист VU. Размерность сырых данных 185 строк на 34 столбца. Среди столбцов присутствуют служебные (номер скважины, дата) и одна особенная колонка КГФ.1, в которой записан тот же газоконденсатный фактор, но в других единицах: КГФ в $г/м^3$, КГФ.1 в $т/тыс.м^3$. Их пропуски не пересекаются: КГФ заполнен в 23 строках, КГФ.1 в 70. Конвертирую КГФ.1 в $г/м^3$ через коэффициент 1000 и сливаю с КГФ, что увеличивает размер рабочей выборки.

Задачи работы:

1. Удалить строки, в которых обе целевые переменные пусты.
2. Заменить нечисловые маркеры пропусков на NaN.
3. Сохранить названия признаков.
4. Построить гистограмму важности признаков по gain ratio.
5. Построить тепловую карту корреляций (по модулю) для всех признаков, включая целевые.
6. Для каждого признака построить распределение с линиями Q1 и Q3.
7. Посчитать описательную статистику для каждого признака.
8. Сформировать список оставленных и удалённых признаков с обоснованием.

ВЫПОЛНЕНИЕ РАБОТЫ

Очистка данных

Снимаю служебные столбцы Unnamed: 0 (номер скважины) и Unnamed: 1 (дата). Все объектные столбцы конвертирую в числовые: запятая на точку, значения, неприводимые к числу, превращаются в NaN.

Объединяю КГФ и КГФ.1 в единый столбец КГФ через перевод единиц. Связь между единицами:

$$1 \text{ т / тыс. м}^3 = \frac{10^6 \text{ г}}{10^3 \text{ м}^3} = 10^3 \text{ г / м}^3 \quad (1)$$

Из соотношения (1) получаю правило заполнения пропусков КГФ значениями КГФ.1, умноженными на 1000:

$$KGF_i = \begin{cases} KGF_i, & KGF_i \neq NaN \\ 10^3 \cdot KGF_{.1_i}, & KGF_i = NaN \end{cases} \quad (2)$$

где i индекс строки, KGF значение в г/м³, KGF.1 значение в т/тыс.м³.

После применения правила (2) столбец КГФ.1 удаляю. По условию работы удаляю строки, в которых одновременно пусты G_total и КГФ. После этого остаётся 93 строки и 31 столбец, из них 29 признаков и 2 таргета. В 23 строках заполнены оба таргета, в 70 строках только КГФ.

Анализ пропусков

Доли пропусков по столбцам после очистки приведены в таблице 1. G_total, Ro_w и Ro_g имеют 75% пропусков, потому что эти величины замерены только в подвыборке исследований ГКИ (23 из 93 строк). Решения по столбцам с пропусками описаны ниже в разделе "Отбор признаков".

Таблица 1 — Доли пропусков по столбцам после очистки (93 строки)

Признак	Доля пропусков, %
G_total	75,3
Ro_g	75,3
Ro_w	75,3

Тна шлейфе	35,5
Рпл. Тек (Карноухов)	31,2
Рпл. Тек (Расчет по КВД)	12,9
Рпл. Тек (послед точка на КВД)	5,4
Дебит смеси	4,3
Глубина манометра, Рзаб, Рзаб.1, Тзаб	3,2

Гистограмма важности признаков (gain ratio)

Признаки оцениваются по gain ratio, нормированному приросту информации. Числовой признак X и таргет Y предварительно дискретизируются квантильным разбиением на $k=10$ интервалов: границы интервалов берутся как выборочные квантили уровня j/k для $j=1, \dots, k-1$. После дискретизации работаем с категориальными величинами.

Базовая величина это энтропия Шеннона распределения таргета:

$$H(Y) = - \sum_{y \in \mathcal{Y}} p(y) \log_2 p(y) \quad (3)$$

где $p(y)$ доля наблюдений с категорией y таргета, $\mathcal{Y}$ множество категорий.

Энтропия (3) измеряет неопределённость таргета в битах. Условная энтропия таргета при заданном признаке X считается как взвешенное среднее энтропий внутри групп, образованных значениями X :

$$H(Y/X) = \sum_{v \in \mathcal{X}} \frac{|S_v|}{|S|} H(Y/X=v) \quad (4)$$

где S_v подмножество наблюдений, в которых $X=v$, $|S|$ общее число наблюдений.

Разность (3) и (4) даёт прирост информации (information gain):

$$IG(Y, X) = H(Y) - H(Y/X) \quad (5)$$

Чем больше $IG(5)$, тем сильнее знание X сокращает неопределённость Y . Проблема чистого IG в том, что он систематически завышает оценку для признаков с большим числом значений. Поэтому делим IG на собственную энтропию признака, она же split information:

$$SplitInfo(X) = - \sum_{v \in \mathcal{X}} \frac{|S_v|}{|S|} \log_2 \frac{|S_v|}{|S|} \quad (6)$$

Итоговая метрика, нормированный gain ratio, считается по формуле:

$$GR(Y, X) = \begin{cases} \frac{IG(Y, X)}{SplitInfo(X)}, & SplitInfo(X) > 0 \\ 0, & SplitInfo(X) = 0 \end{cases} \quad (7)$$

Формула (7) применяется для двух таргетов отдельно. Из-за того, что G_total заполнен в 23 строках, а КГФ в 93, для каждого таргета беру только строки, где он не пуст, и считаю gain ratio на своей подвыборке. Финальный балл признака это среднее по двум таргетам:

$$\overline{GR}(X) = \frac{1}{|\mathcal{T}|} \sum_{Y \in \mathcal{T}} GR(Y, X) \quad (8)$$

где T множество таргетов, в работе T={G_total, КГФ}.

Среднее по (8) исключает ситуацию, когда признаки получают высокий gain ratio за счёт совпадения паттерна пропусков с таргетом.




Рисунок 1 — Средний gain ratio по признакам (G_total и КГФ)

Лидеры по информативности: Ro_g (0,612), Дебит смеси (0,571), Тна шлейфе (0,571), Дебит газа (0,559), Глубина манометра (0,541). Нулевую информативность даёт только Ro_w (константа 1000 на всех заполненных

строках), что согласуется с определением: для константного признака SplitInfo=0 и по второму случаю в (7) присваивается значение 0. Нэф имеет средний gain ratio 0,161, что на грани значимости.

Полезно посмотреть на gain ratio отдельно по двум таргетам, потому что размер подвыборок сильно разный. Для G_total баллы стабильно лежат в диапазоне 0,55-0,90, для КГФ 0,20-0,50. Высокие баллы по G_total объясняются малостью подвыборки (23 строки): при 10 квантильных бинах в каждом оказывается по 2-3 наблюдения, и почти любой признак идеально сегментирует таргет. Поэтому полагаться только на ранжировку по G_total нельзя, КГФ даёт более информативную картину.




Рисунок 2 — Gain ratio по каждому таргету отдельно (порядок по среднему)

Тепловая карта корреляций

Корреляция оценивается коэффициентом Пирсона по парам признаков. Для двух числовых рядов X и Y длины n используется формула:

$$r(X, Y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}} \quad (9)$$

где $\bar{x}$, $\bar{y}$ выборочные средние X и Y, n число пар наблюдений без пропусков.

Эквивалентная запись через ковариацию и стандартные отклонения:

$$r(X, Y) = \frac{\text{cov}(X, Y)}{\sigma_X \cdot \sigma_Y}, \quad r \in [-1, 1] \quad (10)$$

Значение r из (9) отражает силу и знак линейной связи. Для тепловой карты беру значения по модулю, чтобы оба направления связи (прямая и обратная) подсвечивались одинаково:

$$R_{ij} = |r(X_i, X_j)|, \quad R_{ij} \in [0, 1] \quad (11)$$

где i, j индексы пары признаков (включая таргеты), R матрица абсолютных корреляций.

Матрица (11) считается по всем 29 признакам и 2 таргетам. При вычислении pandas попарно отбрасывает строки с NaN, что для разнородных пропусков корректно. На карте видны крупные блоки сильно связанных признаков: давления, дебиты, плотности.




Рисунок 3 — Матрица абсолютных корреляций между признаками и таргетами

Пары признаков с $|r|$ больше 0,95 (мультиколлинеарность):

Таблица 2 — Пары признаков с абсолютной корреляцией выше 0,95

Признак А	Признак В	$ r $
Рсб	Рсб.1	1,000
Ro_g	Удельная плотность газа	1,000
Руст	Руст.1	0,999
Дебит газа	Дебит смеси	0,999
Дебит смеси	G_total	0,996
Дебит газа	G_total	0,993
Рзаб	Рзаб.1	0,978
Дебит воды	Дебит воды.1	0,975
Дебит ст. конд.	G_total	0,967
Дебит газа	Дебит гааз	0,954
Рпл. Тек (Расчет по КВД)	Рпл. Тек (Карноухов)	0,950

Отдельный случай: тройка Дебит газа, Дебит смеси, Дебит ст. конд. имеет $|r|$ выше 0,96 с самим G_total. Эти признаки связаны с таргетом через массовый баланс: G_total складывается из массы газа (Дебит газа умножить на Ro_g), массы стабильного конденсата и массы воды. Прямое включение этой тройки в модель регрессии даёт target leakage, поэтому в обучении они не используются. Однако перед удалением их можно задействовать для восстановления G_total на тех 70 строках, где таргет пуст: 23 полные строки калибруют формулу баланса, дальше формула применяется к остальным. Так синтетическим путём появляется 93 строки с таргетом, после чего тройка выкидывается, и модель обучается на оставшихся 16 признаках (давления, температуры, диаметр штуцера, плотности). Валидация при этом проводится только на исходных 23 строках с измеренным G_total, чтобы не получить оптимистичную оценку качества.

Распределения признаков с квантилями

Для каждого признака строится гистограмма с нанесёнными вертикальными линиями Q1 и Q3 (первый и третий квартили). Квантиль уровня α определяется как такое значение, ниже которого лежит доля α наблюдений:

$$Q_{\alpha} = \inf \{ x \in \mathbb{R} : F(x) \geq \alpha \}, \quad \alpha \in (0, 1) \quad (12)$$

где $F(x)$ выборочная функция распределения, α уровень квантиля.

Из определения (12) первый и третий квартили это:

$$Q_1 = Q_{0,25}, \quad Me = Q_{0,5}, \quad Q_3 = Q_{0,75} \quad (13)$$

Линии Q1 и Q3 на гистограмме делят выборку на четыре равные по числу наблюдений части. Полный набор графиков сохранён в каталоге `assets/distributions/`, ниже приведены примеры для целевой переменной КГФ и для самого информативного признака `Ro_g`.




Рисунок 4 — Распределение целевой переменной КГФ с линиями Q1 и Q3




Рисунок 5 — Распределение признака 'Ro_g' с линиями Q1 и Q3

Описательная статистика

Описательная статистика рассчитана на отфильтрованной выборке (93 строки). Столбец count показывает фактическое число непустых наблюдений по каждому признаку и помогает увидеть, какие столбцы содержат много пропусков. Выборочное среднее и несмещённое стандартное отклонение считаются по классическим формулам:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} \quad (14)$$

где $\bar{x}$ среднее, s несмещённое стандартное отклонение, n число непустых наблюдений по признаку.

Деление на $n-1$ в (14) даёт несмещённую оценку дисперсии (коррекция Бесселя), это поведение pandas по умолчанию. Значения min и max это просто крайние порядковые статистики выборки.

Таблица 3 — Описательная статистика по признакам после очистки

Признак	count	mean	std	min	Q1	media n	Q3	max
Глубина	90	3524,09	144,47	3276,00	3427,62	3579,00	3652,25	3670,00

манометра								
Дшт	93	10,95	2,42	6,35	9,53	11,11	12,70	15,88
Руст	93	228,29	41,90	138,16	201,64	229,89	252,00	337,11
Рзаб	90	331,76	56,48	174,00	297,80	337,79	364,15	458,60
Рлин	93	99,86	7,30	73,31	95,95	100,80	103,87	121,68
Руст.1	93	227,64	41,76	136,00	200,00	228,00	252,00	333,00
Рзаб.1	90	330,33	56,36	174,00	294,62	334,25	362,15	458,50
Рлин	93	98,01	12,43	40,74	95,34	100,26	104,00	123,62
Туст	93	56,17	11,25	24,20	50,30	58,00	64,00	75,00
Тна шлейф е	60	43,09	19,60	14,00	33,30	38,70	46,38	110,20
Тзаб	90	104,96	1,25	100,21	104,52	105,11	105,57	107,07
Тлин	93	39,80	8,94	16,20	33,69	40,52	47,80	55,51
Дебит газа	93	394,40	150,35	128,37	287,95	383,72	489,67	846,82
Дебит ст. конд.	93	99,91	49,14	33,63	69,90	89,80	117,60	302,62
Дебит воды	93	2,13	1,87	0,00	0,70	1,40	3,20	8,34
Дебит смеси	89	417,02	157,75	136,82	306,24	401,39	509,05	896,91
Дебит гааз	93	3282,9 7	1353,0 4	884,00	2223,0 0	3112,0 0	4165,0 0	6943,1 0
Дебит кон нестаб ильны й	93	164,15	85,23	59,80	116,80	143,50	185,20	492,80
Дебит воды.1	93	2,16	1,90	0,00	0,70	1,40	3,30	8,10
Нэф	93	52,70	12,15	30,00	44,20	56,80	63,50	72,54
Рпл. Тек (после д	88	40,68	5,37	29,17	37,21	39,47	42,86	53,27

точка на КВД)								
Рпл. Тек (Расчет по КВД)	81	50,94	4,38	39,90	48,30	50,80	55,40	56,70
Рпл. Тек (Карно ухов)	64	50,77	4,01	41,60	49,42	50,90	52,70	56,80
Рсб	93	95,16	5,14	85,50	90,70	94,20	99,80	104,00
Рсб.1	93	93,92	5,07	84,38	89,51	92,97	98,49	102,64
Ro_g	23	0,8076	0,015	0,7874	0,7874	0,8060	0,8213	0,8243
Ro_c	93	780,85	62,80	186,00	782,00	787,00	793,70	801,00
Ro_w	23	1000,00	0,00	1000,00	1000,00	1000,00	1000,00	1000,00
Удельная плотность газа	93	0,67	0,02	0,57	0,66	0,67	0,68	0,68
G_total	23	5,74	2,11	2,78	4,38	5,25	6,13	10,93
КГФ	93	201,71	49,25	131,00	164,00	192,00	224,00	385,42

Политика по пропускам и выбросам

По условию работы пропуски и выбросы обрабатываются после расчёта корреляций и важности, что и сделано выше. Стандартное правило 1,5 IQR (Тьюки) определяет выбросы через межквартильный размах:

$$IQR = Q_3 - Q_1 \quad (15)$$

$$x_i \text{ выброс, если } x_i < Q_1 - 1,5 \cdot IQR \text{ или } x_i > Q_3 + 1,5 \cdot IQR \quad (16)$$

В этой работе правило (16) не применяю по причинам, изложенным ниже.
Принятые решения:

- Имьютация пропусков на этом этапе не выполняется. Сохранение NaN не мешает корреляциям (pandas игнорирует строки с NaN попарно), а в gain ratio я для каждого таргета отдельно беру только строки, где этот таргет не пуст. Так не возникает ситуация, когда признаки получают преимущество за счёт совпадения паттерна пропусков с таргетом.
- Выбросы по 1,5 IQR (15) не отсекаются: рабочий датасет невелик (93 строки), а аномально высокие значения дебитов и давлений физически правдоподобны и не являются опечатками.
- Признак Ro_w удаляется как константа (std равно 0). Нэф остаётся: его gain ratio 0,161, не нулевой.

Отбор признаков

Правила отбора применяются последовательно:

1. Если средний gain ratio по двум таргетам равен 0, признак удаляется.
2. Если $|r|$ между парой признаков выше 0,95, в паре оставляется тот, у кого выше gain ratio, второй удаляется.
3. Доля пропусков выше 80% также служила бы поводом для удаления, но среди признаков такой ситуации нет, максимальная доля 75% у Ro_g и Ro_w, и они уже попадают под другие правила.

Итог: 20 признаков остаются, 9 удаляются. Итоговое решение по каждому признаку приведено в таблице 4. Дебит смеси и Дебит ст. конд. в таблице остаются по gain ratio, Дебит газа уже удалён по мультиколлинеарности. На этапе моделирования регрессии все три также убираются как target leakage, но до удаления их используем для восстановления G_total на 70 строках с пустым таргетом через формулу массового баланса.

Таблица 4 — Итоговый список признаков с решением и обоснованием

Признак	Решение	Обоснование
Глубина манометра	Оставить	gain ratio = 0,541
Дшт	Оставить	gain ratio = 0,488
Руст	Оставить	gain ratio = 0,508
Рзаб	Удалить	мультиколлинеарность с

		Рзаб.1 ($ r =0,978$)
Рлин	Оставить	gain ratio = 0,420
Руст.1	Удалить	мультиколлинеарность с Руст ($ r =0,999$)
Рзаб.1	Оставить	gain ratio = 0,526
Рлин	Оставить	gain ratio = 0,447
Туст	Оставить	gain ratio = 0,476
Тна шлейфе	Оставить	gain ratio = 0,571
Тзаб	Оставить	gain ratio = 0,480
Тлин	Оставить	gain ratio = 0,513
Дебит газа	Удалить	мультиколлинеарность с Дебит смеси ($ r =0,999$)
Дебит ст. конд.	Оставить	gain ratio = 0,522
Дебит воды	Оставить	gain ratio = 0,480
Дебит смеси	Оставить	gain ratio = 0,571
Дебит гааз	Удалить	мультиколлинеарность с Дебит газа ($ r =0,954$)
Дебит кон нестабильный	Оставить	gain ratio = 0,485
Дебит воды.1	Удалить	мультиколлинеарность с Дебит воды ($ r =0,975$)
Нэф	Оставить	gain ratio = 0,161
Рпл. Тек (послед точка на КВД)	Оставить	gain ratio = 0,506
Рпл. Тек (Расчет по КВД)	Удалить	мультиколлинеарность с Карноухов ($ r =0,950$)
Рпл. Тек (Карноухов)	Оставить	gain ratio = 0,538
Рсб	Оставить	gain ratio = 0,441
Рсб.1	Удалить	мультиколлинеарность с Рсб ($ r =1,000$)
Ro_g	Оставить	gain ratio = 0,612
Ro_c	Оставить	gain ratio = 0,469
Ro_w	Удалить	константа (std=0), gain ratio = 0
Удельная плотность газа	Удалить	мультиколлинеарность с Ro_g ($ r =1,000$)

ЗАКЛЮЧЕНИЕ

1. Заметил, что КГФ и КГФ.1 это одна и та же величина в разных единицах (г/м^3 и т/тыс.м^3). Объединил их через коэффициент 1000, что увеличило выборку с 23 до 93 строк.
2. Из 185 строк сырых данных после удаления записей, где оба таргета пусты, осталось 93 строки. КГФ заполнен во всех 93, G_total только в 23 строках, поэтому gain ratio для каждого таргета считается на своей подвыборке и потом усредняется.
3. Информативность 29 признаков оценена через gain ratio с дискретизацией квантилями. Лидируют Ro_g , Дебит смеси, $T_{на}$ шлейфе, Дебит газа, Глубина манометра со значениями 0,54-0,61. Ro_w даёт нулевой gain ratio как константа 1000.
4. Корреляционный анализ выявил 11 пар с $|r|$ выше 0,95, в каждой удалён менее информативный признак. Тройка Дебит газа, Дебит смеси, Дебит ст. конд. коррелирует с G_total выше 0,96, потому что эти величины входят в массовый баланс с участием Ro_g . На этапе моделирования их выкидываем как target leakage, но перед этим используем для восстановления G_total на 70 строках, где он пуст: формула баланса калибруется на 23 полных строках и переносится на остальные. После восстановления модель обучается без этой тройки, а валидация остаётся на 23 настоящих значениях G_total .
5. Итоговый набор: 20 признаков для дальнейшего моделирования, 9 удалены по причинам мультиколлинеарности или константности.
6. Импьютация пропусков и срез выбросов на этом этапе не применялись, решения обоснованы малым объёмом выборки и физической природой данных.