

Министерство науки и высшего образования Российской Федерации
федеральное государственное автономное образовательное учреждение
высшего образования
«Национальный исследовательский университет ИТМО»

Факультет программной инженерии и компьютерной техники

Лабораторная работа №4

По дисциплине "Основы машинного обучения" на тему
"Машины опорных векторов в задаче определения Р300"

Группа: Р3324

Выполнил: Пахомов Владислав
Владимирович

Проверила:

к.т.н. доцент Солодка М.А.

ОГЛАВЛЕНИЕ

ВВЕДЕНИЕ	3
ВЫПОЛНЕНИЕ РАБОТЫ.....	4
Описание данных и извлечение эпох	4
Признаки.....	4
Subject-wise split.....	4
Linear SVM (Pegasos).....	5
Метрики качества	7
ЗАКЛЮЧЕНИЕ.....	10

ВВЕДЕНИЕ

Цель работы: освоить машины опорных векторов на задаче определения потенциала P300 в данных EEG. Реализовать линейный SVM с нуля, обучить его на нескольких субъектах и оценить качество на отдельном испытуемом.

Источник данных: MOABB, dataset BNCI2014-009, классическая P300-парадигма (speller). 10 субъектов, 18 EEG-каналов, частота 256 Гц. В работе берутся три субъекта (1, 2 и 3) для баланса между объёмом данных и временем загрузки.

Задачи работы:

1. Проанализировать данные, выделить эпохи и обосновать набор признаков.
2. Обучить SVM в задаче P300 vs NonTarget, обосновать выбор типа машины и ядра.
3. Посчитать accuracy, precision, recall и F1.
4. Построить ROC-кривую и AUC.

ВЫПОЛНЕНИЕ РАБОТЫ

Описание данных и извлечение эпох

МОАВВ отдаёт сырые сессии в формате MNE Raw с аннотациями стимулов. Через `mne.events_from_annotations` извлекается таблица событий и словарь `event_id` с ключами `Target` и `NonTarget`. Для каждого стимула вырезается эпоха длиной 0-800 мс от его начала, baseline-коррекция отключена.

Тонкий момент с разбором `event_id`. Кажется естественным написать `'Target' in key`, чтобы выудить целевые коды. Это ловушка: подстрока `'Target'` входит и в `'NonTarget'`, поэтому такая проверка одновременно ловит оба класса. В работе используется точное сравнение по нижнему регистру: `k.strip().lower() == 'target'` и аналогично для `nontarget`.

После сбора по трём субъектам получается 5184 эпохи формы (5184, 18, 206), по 1728 на каждого. Распределение классов одинаково у всех: 288 `Target` и 1440 `NonTarget`, естественный дисбаланс 1 к 5, типичный для P300-paradigm.

Признаки

Для каждой эпохи вычисляется средняя амплитуда сигнала по 5 равным временным окнам длиной 160 мс: 0-160, 160-320, 320-480, 480-640, 640-800 мс. Окна охватывают весь временной интервал и попадают на пик P300, который у большинства субъектов виден около 300 мс после стимула.

Признаков получается 18 каналов на 5 окон, итого 90 чисел на эпоху. Этот набор простой, не требует обучения экстрактора, и хорошо работает на линейных классификаторах для ERP-сигнала. Альтернативы вроде xDAWN или Riemannian features добавили бы качества, но в требования ЛР не входят.

Subject-wise split

Случайное перемешивание эпох по всем субъектам приводит к завышенной оценке: эпохи одного человека попадают и в `train`, и в `test`, и классификатор учит индивидуальные особенности. Чтобы получить честные числа, `train` берётся по субъектам [1, 2], `test` по субъекту [3]. Это эмулирует

ситуацию, когда BCI настраивается на новых пользователях по записям предшественников.

Train: 3456 эпохи (576 Target, 2880 NonTarget). Поскольку отношение 1 к 5 делает SVM ленивым (тривиальный классификатор всегда NonTarget даёт accuracy 0,83), проводится undersampling NonTarget до 2:1: остаётся 1152 NonTarget, 576 Target, всего 1728 объектов на тренировке.

Test: 1728 эпох субъекта 3 без всякого undersampling, естественный дисбаланс сохраняется. Это правильно, для оценки в реальном применении класс Target всё равно встречается реже.

Linear SVM (Pegasos)

Pegasos, стохастический субградиентный спуск на регуляризованной hinge-loss. Целевая функция:

$$L(w, b) = \frac{\lambda}{2} \|w\|^2 + \frac{1}{n} \sum_{i=1}^n \max(0, 1 - y_i(w \cdot x_i + b)) \quad (1)$$

где w вектор весов, b смещение, $\lambda = 1/C$ коэффициент регуляризации, $y_i \in \{-1, +1\}$, n число объектов train.

Целевая функция (1), L2-регуляризация плюс hinge-loss. Hinge активен только на объектах с маленьким margin:

$$m_i = y_i (w \cdot x_i + b) \quad (2)$$

Margin (2) положителен на корректно классифицированных объектах, отрицателен на ошибках. На итерации t выбирается случайный объект i , шаг обучения убывает гиперболически:

$$\eta_t = \frac{1}{\lambda t} \quad (3)$$

При $m_i < 1$ (объект попал внутрь margin или с неправильной стороны границы) обновление по (3) включает регуляризацию и градиент hinge:

$$w \leftarrow (1 - \eta_t \lambda) w + \eta_t y_i x_i, b \leftarrow b + \eta_t y_i \quad (4)$$

Обновление (4). Иначе работает только сжатие весов на $(1 - \eta_t \lambda)$, смещение b не меняется. Уменьшение η_t гарантирует сходимость стохастического спуска на выпуклой целевой.

Параметры: $C = 1$, отсюда $\lambda = 1$, $\max_iter = 3000$, $\text{random_state} = 42$. Тренировка занимает примерно 7 миллисекунд (90 признаков, 1728 объектов в train). Метки переводятся из $\{0, 1\}$ в $\{-1, +1\}$ для совместимости с формулой hinge.

Выбор линейного ядра обоснован двумя соображениями. ERP-разделение Target/NonTarget описывается линейной комбинацией амплитуд, в литературе это давно показано (LDA, sLDA на P300 работают сравнимо с RBF). При 90 признаках и 1728 объектов нелинейные ядра легко переобучаются и теряют обобщение между субъектами.



Рисунок 1 — Кривая обучения SVM, hinge + регуляризация по итерациям

Loss падает с 0,56 до плато около 0,38 за первые 1000 итераций. Дальше колебания около плато, типичное поведение стохастического спуска: обновления зависят от случайного объекта, поэтому идеально гладкой сходимости не получается.

Метрики качества

На тесте subject 3 (1728 эпох, естественный 1:5) считаются стандартные метрики бинарной классификации по матрице ошибок (TP, TN, FP, FN). Доля верных ответов:

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN} \quad (5)$$

Accuracy (5) при сильном дисбалансе обманчива: тривиальный классификатор всегда NonTarget даёт уже 0,83. Поэтому ключевые метрики precision и recall на положительном классе:

$$\text{Precision} = \frac{TP}{TP+FP}, \text{Recall} = \frac{TP}{TP+FN} \quad (6)$$

Precision и recall (6), доля верных среди предсказанных положительных и доля найденных среди истинных положительных. F1 это их гармоническое среднее:

$$F_1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (7)$$

F1 (7) объединяет precision и recall в одно число, штрафую, если хоть одна из них низкая. Macro-усреднение считает метрики на каждом классе отдельно и берёт среднее с равным весом, чтобы не маскировать качество на минорном Target. Для ROC и AUC нужны доли:

$$\text{TPR} = \frac{TP}{TP+FN}, \text{FPR} = \frac{FP}{FP+TN} \quad (8)$$

TPR и FPR (8) считаются на скользящем пороге по decision-function классификатора. AUC, площадь под получившейся ROC-кривой, число от 0 до 1: AUC = 1 идеальное ранжирование, 0,5 случайное, ниже 0,5 хуже случайного.

Таблица 1 — Метрики SVM на тестовом субъекте

Метрика	Значение
Accuracy	0,977
Precision (macro)	0,963
Recall (macro)	0,953
F1 (macro)	0,958

AUC	0,995
-----	-------




Рисунок 2 — Матрица ошибок на тестовом субъекте

Из матрицы ошибок: $TN = 1424$, $FP = 16$, $FN = 24$, $TP = 264$. На целевом классе $recall = 264 / 288 = 0,917$, $precision = 264 / 280 = 0,943$. Из 288 истинных Target пропущено 24 эпохи (8 процентов), при этом ложных срабатываний всего 16 на 1440 NonTarget (1,1 процента).




Рисунок 3 — ROC-кривая SVM, $AUC = 0,995$

ROC-кривая практически прижата к левому верхнему углу: при FPR около 5 процентов TPR уже выше 95. $AUC = 0,995$ говорит о почти идеальном порядковом разделении классов в decision-function. На практике это значит, что выбор порога между классами сводится к тонкой настройке trade-off между пропусками и ложными срабатываниями.

ЗАКЛЮЧЕНИЕ

1. Linear SVM с Pegasos-обновлением реализован с нуля на numpy: hinge loss с регуляризацией по $\lambda = 1/C$, learning rate $1 / (\lambda * t)$, 3000 стохастических итераций. Тренировка занимает около 7 миллисекунд.
2. Признаки, средние амплитуды по 5 временным окнам и 18 каналам, всего 90 чисел на эпоху. Простой набор, ловящий пик P300 без обучения экстрактора.
3. Subject-wise split (train на S1, S2, test на S3) даёт честную оценку обобщения на нового пользователя. В train применён undersampling до 2:1, в test сохранён естественный дисбаланс 1 к 5.
4. На тесте subject 3 получены: Accuracy = 0,977, Precision = 0,963, Recall = 0,953, F1 = 0,958, AUC = 0,995. Линейная граница между Target и NonTarget хорошо переносится с одних людей на других.
5. Линейное ядро обосновано высокой размерностью признаков и характером ERP: нелинейные ядра при 90 признаках и 1728 train-объектов легко переобучаются.