

Министерство науки и высшего образования Российской Федерации
федеральное государственное автономное образовательное учреждение
высшего образования
«Национальный исследовательский университет ИТМО»

Факультет программной инженерии и компьютерной техники

Лабораторная работа №5

По дисциплине "Основы машинного обучения" на тему
"Градиентный бустинг в задаче распознавания
человеческой активности"

Группа: P3324

Выполнил: Пахомов Владислав
Владимирович

Проверила:

к.т.н. доцент Солодка М.А.

Санкт-Петербург

2026

ОГЛАВЛЕНИЕ

ВВЕДЕНИЕ	3
ВЫПОЛНЕНИЕ РАБОТЫ.....	4
Описание датасета	4
Базовый предсказатель: decision stump	4
Бинарный gradient boosting на log-loss	5
Расширение до 6 классов: One-vs-Rest	6
Гиперпараметры и обоснование.....	6
Обучение	7
Метрики качества	7
Матрица ошибок.....	8
ROC-кривая по классам	9
ЗАКЛЮЧЕНИЕ.....	11

ВВЕДЕНИЕ

Цель работы: реализовать градиентный бустинг с нуля и применить его к задаче распознавания человеческой активности по показаниям акселерометра и гироскопа смартфона.

Источник данных: UCI Human Activity Recognition Using Smartphones. 30 испытуемых выполняли 6 видов активностей с телефоном на поясе: ходьба, подъём по лестнице, спуск, сидение, стояние, лёжа. Из сигналов извлечены 561 предвычисленный признак (статистики во временном и частотном доменах). Тренировочная часть 7352 примеров, тестовая 2947.

Задачи работы:

1. Реализовать градиентный бустинг с нуля, обосновать выбор гиперпараметров.
2. Посчитать accuracy, precision, recall и F1.
3. Построить ROC-кривую и AUC по классам.

ВЫПОЛНЕНИЕ РАБОТЫ

Описание датасета

UCI HAR содержит шесть классов активностей с примерным балансом, перечисляю объёмы в train: WALKING 1226, WALKING_UPSTAIRS 1073, WALKING_DOWNSTAIRS 986, SITTING 1286, STANDING 1374, LAYING 1407. Test-часть пропорциональна. Признаки (561) уже инженерные: средние, стандартные отклонения, корреляции, спектральные коэффициенты по осям акселерометра и гироскопа в скользящих окнах 2,56 секунды.

Перед обучением применяется z-score стандартизация: среднее и std считаются по train и применяются к test, чтобы не было утечки информации о тестовой выборке.

Базовый предсказатель: decision stump

Бустинг строится поверх слабых классификаторов. В этой работе слабый предсказатель, decision stump (решающий пень), глубина 1: одна проверка вида $x[j] \leq t$, и два листовых значения для левой и правой ветвей.

$$h(x) = c_L \cdot [x_j \leq t] + c_R \cdot [x_j > t] \quad (1)$$

где j индекс признака, t порог, c_L и c_R листовые значения, $[\cdot]$ индикатор условия.

Пень (1) разбивает выборку на две части по признаку j с порогом t . При обучении на остатках (negative gradient log-loss) листовое значение оптимизирует squared error и получается как среднее остатков в листе:

$$c_L = \frac{1}{|S_L|} \sum_{i \in S_L} r_i, c_R = \frac{1}{|S_R|} \sum_{i \in S_R} r_i \quad (2)$$

где S_L и S_R подмножества объектов, попавших в левый и правый листы, r_i остаток объекта i .

Листовые значения (2) это средние residuals по объектам в каждом листе. Поиск лучшего сплита перебирает все признаки в подвыборке и до 50 пороговых значений на каждый, расположенных по квантилям, минимизируя

суммарный MSE по двум листьям. Это сильно ускоряет тренировку по сравнению с проверкой всех уникальных значений.

Бинарный gradient boosting на log-loss

Бинарный классификатор минимизирует log-loss относительно сырого предсказания $F(x)$. Сигмоида переводит F в вероятность класса 1:

$$\sigma(F) = \frac{1}{1+e^{-F}} \quad (3)$$

$$L(y, F) = -[y \log \sigma(F) + (1 - y) \log(1 - \sigma(F))] \quad (4)$$

где $y \in \{0, 1\}$ истинная метка, $F(x)$ сырое предсказание ансамбля.

Сигмоида (3) и log-loss (4) задают целевую функцию, штрафующую уверенно неверные ответы. Алгоритм обучения последовательный. Стартовое значение, логарифм отношения шансов:

$$F_0 = \log \frac{p}{1-p} \quad (5)$$

где p доля положительных объектов в train, F_0 даёт калиброванное стартовое распределение вероятностей.

Стартовое значение (5). На итерации m считается отрицательный градиент log-loss по F :

$$r_i^{(m)} = -\frac{\partial L}{\partial F} \Big|_{F=F_m(x_i)} = y_i - \sigma(F_m(x_i)) \quad (6)$$

Residuals (6) показывают, насколько предсказанная вероятность отстаёт от истинной метки. На residuals обучается decision stump h_m , далее ансамбль сдвигается в сторону остатков:

$$F_{m+1}(x) = F_m(x) + v \cdot h_m(x) \quad (7)$$

где v learning rate (0,1 в работе), h_m пень, обученный на residuals.

Обновление ансамбля (7) с малым v сжимает шаг и работает как регуляризация: маленький v при том же числе деревьев даёт более плавную сходимость и лучшее обобщение.

На каждой итерации признаки для поиска сплита выбираются случайной подвыборкой размера `max_features`. Это снижает корреляцию между последовательными деревьями и работает как мягкая регуляризация.

Расширение до 6 классов: One-vs-Rest

Для multi-class задачи строится 6 независимых бинарных бустингов, каждый различает свой класс против всех остальных. На предсказании берутся 6 sigmoid-вероятностей и нормируются по сумме:

$$\hat{p}_k(x) = \frac{\sigma(F^{(k)}(x))}{\sum_{j=1}^K \sigma(F^{(j)}(x))}, \hat{y} = \arg \max_k \hat{p}_k(x) \quad (8)$$

где K число классов (6 в работе), $F^{(k)}$ ансамбль для класса k против всех остальных, $\hat{p}_k$ нормированная вероятность.

Нормировка (8) делает вектор вероятностей суммирующимся в единицу, $\arg \max$ выбирает класс с максимальной нормированной вероятностью.

OvR проще честного multinomial-лога и вписывается в готовый бинарный движок без переписывания. Цена, классификаторы не используют общую структуру задачи: каждый учится отдельно. Для HAR с относительно разнесёнными классами это не критично.

Гиперпараметры и обоснование

- `n_estimators = 100`. Достаточно для сходимости log-loss на HAR (видно на графике loss, плато по концу обучения), при этом не нужно пересчитывать модель на сотни тысяч итераций.
- `learning_rate = 0,1`. Стандартное компромиссное значение: меньшие значения требуют больше деревьев, большие провоцируют переобучение.
- `max_features = 24`, корень из 561. Снижает корреляцию между деревьями, ускоряет тренировку (вместо 561 признака на каждом сплите перебираются 24) и работает как стохастическая регуляризация.
- `random_state = 42` для воспроизводимости.

Обучение

Тренировка шести OvR-классификаторов занимает примерно 26 секунд на ноутбучном процессоре. Кривые log-loss для каждого классификатора приведены на рисунке 1.




Рисунок 1 — Кривые log-loss по итерациям для каждого OvR-классификатора

Все шесть кривых монотонно убывают, без признаков переобучения. Самый быстрый рост качества у LAYING (loss падает с 0,48 до 0,18) и у WALKING_DOWNSTAIRS (с 0,39 до 0,17). Медленнее всего обучаются STANDING и SITTING: эти классы плохо отличимы от позы LAYING/STANDING соответственно.

Метрики качества

На тестовой выборке (2947 примеров) получены следующие агрегаты. Все средние, кроме ассурасу, посчитаны по mасго: каждый класс вносит равный вклад.

Таблица 1 — Сводные метрики gradient boosting на тестовой выборке HAR

Метрика	Значение
Accuracy	0,849
Precision (macro)	0,877

Recall (macro)	0,840
F1 (macro)	0,841

Матрица ошибок




Рисунок 2 — Матрица ошибок по тесту HAR

Главные источники ошибок видны сразу. В блоке движений путаются WALKING, WALKING_UPSTAIRS и WALKING_DOWNSTAIRS: по 90 примеров каждой лестницы попадает в обычную ходьбу. Интуиция понятна, ускорения по осям при движении ногами очень похожи. В блоке статичных поз мощная путаница SITTING и STANDING: 178 примеров SITTING предсказаны как STANDING. Это типичная сложность HAR-датасета: телефон на поясе при сидении и стоянии видит почти одну картину гравитации.

Класс LAYING выделен идеально: 537 из 537 угаданы верно. Лежание сильно отличается ориентацией оси гравитации, и любой метод его выделяет.

ROC-кривая по классам




Рисунок 3 — ROC-кривые One-vs-Rest по шести классам активности

Таблица 2 — AUC по классам

Класс	AUC
WALKING	0,989
WALKING_UPSTAIRS	0,989
WALKING_DOWNSTAIRS	0,973
SITTING	0,972
STANDING	0,980
LAYING	1,000

Все шесть AUC выше 0,97, ROC-кривые прижаты к левому верхнему углу. Это говорит, что бустинг хорошо ранжирует объекты внутри каждого OvR-классификатора. Сравнительно низкие ассурасу и recall (0,849 и 0,840) при

таких AUC означают, что проблема не в плохом ранжировании, а в неоптимальной конкуренции вероятностей между близкими классами на этапе argmax . SITTING и STANDING спорят между собой за argmax , и это бьёт по accuracy, не по AUC.

ЗАКЛЮЧЕНИЕ

1. Градиентный бустинг с нуля реализован на decision stumps, log-loss и стохастическом подборе признаков. Для multi-class использована One-vs-Rest обёртка над бинарным классификатором.
2. Гиперпараметры подобраны по соображениям компромисса: 100 деревьев сходятся до плато, learning_rate = 0,1 не даёт переобучаться, max_features = sqrt(561) ускоряет тренировку и снижает корреляцию деревьев.
3. На UCI HAR метрики получены такие: Accuracy = 0,849, Precision (macro) = 0,877, Recall (macro) = 0,840, F1 (macro) = 0,841. AUC по всем классам выше 0,97.
4. Класс LAYING выделяется идеально (537 / 537). Динамические активности (walking-варианты) путаются между собой, статичные позы SITTING/STANDING тоже спорят между собой за argmax. Это ограничение датасета, а не алгоритма.
5. Высокие AUC при средних accuracy и recall говорят, что бустинг хорошо ранжирует, но при близких вероятностях соседних классов argmax ошибается. Лучший recall дал бы калиброванный multinomial-вариант или меньший шаг и больше деревьев.