

Министерство науки и высшего образования Российской Федерации
федеральное государственное автономное образовательное учреждение
высшего образования
«Национальный исследовательский университет ИТМО»

Факультет программной инженерии и компьютерной техники

Лабораторная работа №6

По дисциплине "Основы машинного обучения" на тему
"Random Forest в задаче классификации поверхности по
данным IMU-сенсоров"

Группа: P3324

Выполнил: Пахомов Владислав
Владимирович

Проверила:

к.т.н. доцент Солодкая М.А.

Санкт-Петербург

2026

ОГЛАВЛЕНИЕ

Оглавление будет сформировано автоматически при обновлении поля (ПКМ → «Обновить поле»)

ВВЕДЕНИЕ

Цель работы: реализовать алгоритм Random Forest с нуля и применить его к задаче классификации типа поверхности по показаниям инерциальных датчиков (IMU) робота.

Источник информации: соревнование Kaggle CareerCon 2019, Help Navigate Robots. Робот проезжал по 9 разным поверхностям (бетон, soft PVC, дерево, плитка и др.), записывая сигналы 10 каналов IMU (кватернион ориентации, угловая скорость, линейное ускорение) с частотой, дающей 128 замеров на серию. Всего 3810 серий.

Задачи работы:

1. Реализовать решающее дерево с не-бинарным multiway-разбиением узлов и Random Forest как ансамбль таких деревьев.
2. Обосновать ограничение глубины эмпирически.
3. Посчитать accuracy, precision, recall и F1 (по классам и усреднённые).
4. Построить ROC-кривые One-vs-Rest и AUC по классам.

ВЫПОЛНЕНИЕ РАБОТЫ

Описание датасета

Каждая серия (series_id) это один проход робота, 128 последовательных замеров с 10 каналов: ориентация кватернионом (X, Y, Z, W), угловая скорость (X, Y, Z), линейное ускорение (X, Y, Z). Метка surface задаётся на уровне всей серии.

Классы заметно несбалансированы: от 779 серий concrete до 21 серии hard_tiles. Это влияет на оценку: ассигасу сама по себе будет завышена доминирующими классами, поэтому метрики precision/recall/F1 считаются по каждому классу и усредняются.




Рисунок 1 — Распределение классов поверхностей в датасете

Формирование признаков

Дерево решений работает с табличным форматом, а у нас временной ряд из 128 точек на серию. Каждый канал сворачивается в 7 статистических агрегатов: среднее, std, минимум, максимум, медиана, размах, mean-abs-change (оценка дрожания сигнала).

$$MAC(s) = \frac{1}{T-1} \sum_{t=1}^{T-1} |s_{t+1} - s_t| \quad (1)$$

где $T = 128$ длина серии, s_t замер канала в момент t .

MAC (1) даёт оценку высокочастотной составляющей сигнала, насколько сильно отдельные шаги вибрации отличаются от соседних.

Дополнительно строятся два производных канала, модули угловой скорости и линейного ускорения:

$$\|\omega\| = \sqrt{\omega_x^2 + \omega_y^2 + \omega_z^2}, \quad \|a\| = \sqrt{a_x^2 + a_y^2 + a_z^2} \quad (2)$$

Магнитуды (2) дают признаки, инвариантные к ориентации робота. Итого 12 каналов (10 исходных + 2 производных) на 7 статистик это 84 числовых признака на серию.

Разбиение на train и test

Тестовая часть Kaggle (X_test.csv) не содержит меток, поэтому размеченная выборка делится самостоятельно, стратифицированно по классам, в пропорции 75/25. Редкие классы попадают в обе части.

Таблица 1 — Размеры обучающей и тестовой выборок

Часть	Серий
Train	2858
Test	952

Реализация дерева решений

Критерий разбиения, прирост информации (information gain) по энтропии Шеннона. Для множества S с распределением классов p_c :

$$H(S) = - \sum_{c=1}^C p_c \log_2 p_c \quad (3)$$

где C число классов, p_c доля объектов класса c в множестве S .

$$IG(S; split) = H(S) - \sum_{i=1}^k \frac{|S_i|}{|S|} H(S_i) \quad (4)$$

где S_i подмножества-потомки, k число ветвей (от 2 до 4 в этой работе).

Энтропия (3) равна нулю на чистом узле и достигает максимума $\log_2 C$ при равномерном распределении классов. Прирост информации (4) показывает уменьшение энтропии благодаря разбиению. Алгоритм выбирает признак и схему разбиения с максимальным IG.

Не-бинарное разбиение. В классическом CART узел делится надвое (порог $x_f \leq t$). По требованию ТЗ в каждом узле признак разбивается на m из $\{2, 3, 4\}$ диапазонов по квантилям. Перебираются все три варианта, выбирается с максимальным IG.

Не-сбалансированное дерево. Каждая ветвь растёт независимо: критерии остановки ($\max_depth$, $\min_samples$, чистота узла, $IG = 0$) срабатывают в разное время на разных подвыборках, поэтому длины ветвей различаются.

В каждом узле перебирается случайное подмножество $\sqrt{d} = 9$ признаков из 84 имеющихся. Это снижает корреляцию между деревьями в лесу.

Random Forest как ансамбль

Лес обучает 60 деревьев на bootstrap-выборках (выбор с возвращением размером n из $train$). Финальная вероятность класса это среднее по деревьям:

$$P(y=c/x) = \frac{1}{T} \sum_{t=1}^T P_t(y=c/x), \quad \hat{y}(x) = \arg \max_c P(y=c/x) \quad (5)$$

где $T = 60$ число деревьев, P_t вероятность класса c в листе дерева t .

Soft voting (5) усредняет распределения, что снижает дисперсию ансамбля. Дисперсия среднего T независимых случайных величин убывает в T раз, поэтому даже слабые деревья в ансамбле дают сильный классификатор.

Обоснование ограничения глубины

Глубокие деревья запоминают шум обучающей выборки (переобучение): $train$ -accuracy растёт до единицы, $test$ -accuracy выходит на плато. Подбор $\max_depth$: обучаем лес при разных значениях, сравниваем точности на $train$ и $test$.




Рисунок 2 — Зависимость train и test accuracy от max_depth

Таблица 2 — Зависимость accuracy от max_depth (n_trees = 25)

max_depth	train_acc	test_acc
2	0,566	0,596
4	0,870	0,802
6	0,996	0,832
8	0,996	0,832
12	0,996	0,832
15	0,996	0,832
20	0,996	0,832

При малой глубине (2, 4) лес недообучен, точности низкие и на train, и на test. При max_depth = 6 train выходит на плато 0,996, test тоже стабилизируется на 0,832. Дальнейшее увеличение глубины ничего не меняет: деревья достигают чистых листьев раньше, чем упрутся в ограничение. Выбираем max_depth = 6 как минимальное значение с максимальным test, компромисс смещения и разброса.

Проверка не-сбалансированности и не-бинарности

После обучения финального леса с $\text{max_depth} = 6$ распределение глубин листьев по всем 60 деревьям показано на рисунке 3.




Рисунок 3 — Распределение глубин листьев в финальном лесе

Глубины листьев в диапазоне от 3 до 6 при $\text{max_depth} = 6$, среднее примерно 5. Ветви имеют разную длину, дерево не-сбалансированное.

Распределение фактического числа потомков по всем внутренним узлам финального леса:

Таблица 3 — Распределение количества потомков по узлам в финальном лесе

Число потомков	Узлов	Доля
2	698	4,4 %
3	3 303	20,7 %
4	11 942	74,9 %

Три четверти всех решений в лесе это разбиение узла на 4 ветви, бинарные сплиты составляют 4,4 %. Требование 'не бинарное' выполняется содержательно, а не формально.

Метрики качества финальной модели

Итоговая модель: $n_trees = 60$, $\text{max_depth} = 6$, $\text{min_samples} = 5$, $\text{max_bins} = 4$. Метрики на тестовой выборке (952 серии):

$$Precision_c = \frac{TP_c}{TP_c + FP_c}, Recall_c = \frac{TP_c}{TP_c + FN_c}, F_{1,c} = \frac{2P_c R_c}{P_c + R_c} \quad (6)$$

где TP, FP, FN истинно-положительные, ложно-положительные и пропуски для класса c.

Метрики (6) считаются по каждому классу и усредняются: macro даёт равный вес классам, weighted взвешивает по поддержке.

Таблица 4 — Сводные метрики Random Forest на тестовой выборке

Усреднение	Precision	Recall	F1
Macro	0,755	0,737	0,741
Weighted	0,842	0,844	0,840

Ассурасу = 0,844. Метрики по каждому классу:

Таблица 5 — Метрики по классам на тестовой выборке

Класс	Precision	Recall	F1	Support
carpet	0,861	0,660	0,747	47
concrete	0,847	0,877	0,861	195
fine_concrete	0,857	0,659	0,745	91
hard_tiles	0,000	0,000	0,000	5
hard_tiles_large_space	0,958	0,896	0,926	77
soft_pvc	0,879	0,913	0,895	183
soft_tiles	0,767	0,932	0,841	74
tiled	0,843	0,883	0,863	128
wood	0,778	0,809	0,794	152

Класс hard_tiles получает нули по всем метрикам, всего 5 примеров в test и 16 в train, статистики недостаточно для надёжной классификации. Это ограничение датасета, не алгоритма. Остальные классы дают F1 в диапазоне 0,745 до 0,926, доминирующие классы (concrete, soft_pvc, tiled) около 0,86 и выше.

Матрица ошибок




Рисунок 4 — Матрица ошибок на тестовой выборке

Основные пути ошибок интерпретируемы. Wood путается с tiled (10 примеров) и soft_tiles (7), эти материалы имеют похожую низкочастотную вибрацию. Fine_concrete теряется в concrete (7 примеров), физически близкие материалы. Carpet иногда попадает в wood (5), оба относительно мягкие, сигнал по линейному ускорению похож.

ROC-кривая и AUC

ROC строится для бинарной задачи, для 9 классов применяется подход One-vs-Rest: для класса s считается кривая, где $y = s$ положительный, остальные отрицательные. По осям FPR и TPR:

$$T P R = \frac{T P}{T P + F N}, F P R = \frac{F P}{F P + T N} \quad (7)$$

ROC (7) при перемещении порога отсечки. AUC площадь под кривой методом трапеций, интерпретируется как вероятность того, что случайный положительный объект получит более высокий скор, чем случайный отрицательный.




Рисунок 5 — ROC-кривые One-vs-Rest по классам поверхностей

Таблица 6 — AUC по классам и macro-average

Класс	AUC
hard_tiles	0,997
hard_tiles_large_space	0,995
carpet	0,992
soft_pvc	0,990
soft_tiles	0,987
tiled	0,986

wood	0,980
concrete	0,977
fine_concrete	0,954
macro-average	0,984

Все классы имеют AUC выше 0,95, кривые прижаты к левому верхнему углу. Это говорит, что Random Forest хорошо ранжирует объекты внутри каждой OvR-задачи, даже там, где argmax путается из-за близких вероятностей соседних классов. Высокий AUC у `hard_tiles` (0,997) при $F1 = 0$ значит, что 5 положительных примеров всё же получают более высокий скор $P(\text{hard_tiles})$ чем другие, просто этот скор недостаточно высок для argmax .

ЗАКЛЮЧЕНИЕ

1. Random Forest реализован с нуля. Деревья содержат multiway-узлы (от 2 до 4 ветвей по квантилям), 74,9 % узлов в финальном лесу имеют 4 потомка, 20,7 % имеют 3, и только 4,4 % бинарные. Глубины ветвей разные, от 3 до 6 при $\text{max_depth} = 6$, дерево не-сбалансированное.
2. Ограничение глубины обосновано экспериментально: построена зависимость train и test accuracy от max_depth , выбрана точка выхода test на плато ($\text{max_depth} = 6$).
3. На тестовой выборке: Accuracy = 0,844, Precision (macro) = 0,755, Recall (macro) = 0,737, F1 (macro) = 0,741, AUC (macro) = 0,984. Доминирующие классы дают F1 от 0,86 до 0,93. Класс `hard_tiles` нулевой из-за крайне малой статистики (5 test и 16 train примеров).