

Министерство науки и высшего образования Российской Федерации
федеральное государственное автономное образовательное учреждение
высшего образования
«Национальный исследовательский университет ИТМО»

Факультет программной инженерии и компьютерной техники

Лабораторная работа №7

По дисциплине "Основы машинного обучения" на тему
"Многослойный персептрон в задаче классификации
грибов"

Группа: Р3324

Выполнил: Пахомов Владислав
Владимирович

Проверила:

к.т.н. доцент Солодкая М.А.

Санкт-Петербург

2026

ОГЛАВЛЕНИЕ

Оглавление будет сформировано автоматически при обновлении поля (ПКМ → «Обновить поле»)

ВВЕДЕНИЕ

Цель работы: реализовать многослойный персептрон (MLP) с нуля и применить его к задаче бинарной классификации грибов на съедобные и ядовитые.

Источник информации: датасет UCI Mushroom (id = 73), 8124 образца грибов, описанных 22 категориальными признаками (форма и цвет шляпки, запах, характеристики ножки и др.). Каждый гриб отнесён к одному из двух классов: edible (съедобный) или poisonous (ядовитый).

Задачи работы:

1. Загрузить датасет, провести предобработку категориальных признаков (one-hot кодирование) и стратифицированное разбиение на train и test.
2. Реализовать MLP с двумя скрытыми слоями, сигмоидной активацией и одним выходным нейроном на чистом numpy: прямой проход, обратное распространение ошибки, обновление весов.
3. Обучить сеть ванильным градиентным спуском (full-batch) с Xavier-инициализацией весов.
4. Посчитать accuracy, precision, recall, F1, построить матрицу ошибок и ROC-кривую с AUC.

ВЫПОЛНЕНИЕ РАБОТЫ

Описание датасета

Датасет UCI Mushroom содержит 8124 образца, каждый описан 22 категориальными признаками. Все признаки строковые (буквенные коды категорий), числовых признаков в исходных данных нет. Метка `poisonous` задаёт класс: `e` (edible) или `p` (poisonous).

Классы почти сбалансированы: 4208 съедобных грибов и 3916 ядовитых, соотношение примерно 52/48. Сбалансированность означает, что ассигуру является корректной метрикой и не завышается доминирующим классом.

Таблица 1 — Распределение классов в датасете UCI Mushroom

Класс	Образцов	Доля
edible (0)	4208	51,8 %
poisonous (1)	3916	48,2 %
Всего	8124	100 %

Предобработка данных

Признаки категориальные, а нейронная сеть работает с числовыми входами. Прямое преобразование категорий в целые коды некорректно: сеть интерпретировала бы их как порядковые величины, хотя порядка между категориями нет. Поэтому каждый из 22 признаков кодируется one-hot: категория превращается в набор бинарных столбцов, по одному на значение.

Единственный признак с пропусками, `stalk-root`, в загруженных через `usimlгеро` данных отдаёт пропуски как `NaN` (литеральных символов '?' нет, проверка `(X_raw == '?').sum()` возвращает пустой Series). При one-hot такой пропуск становится отдельной категорией со своим бинарным столбцом, то есть трактуется как самостоятельное значение, а не отбрасывается.

После one-hot кодирования всех 22 признаков получается 117 бинарных входов. Целевая переменная кодируется как `p` (poisonous) = 1, `e` (edible) = 0.

Размеченная выборка делится на train и test в пропорции 80/20, стратифицированно по классам, чтобы сохранить баланс классов в обеих частях.

Таблица 2 — Размеры обучающей и тестовой выборок после предобработки

Часть	Образцов	Признаков
Train	6499	117
Test	1625	117

Архитектура MLP

Сеть состоит из входного слоя на 117 нейронов, двух скрытых слоёв и одного выходного нейрона. Конфигурация слоёв [117, 64, 32, 1]:

1. Вход: 117 нейронов (по числу бинарных признаков).
2. Скрытый слой 1: 64 нейрона, сигмоидная активация.
3. Скрытый слой 2: 32 нейрона, сигмоидная активация.
4. Выход: 1 нейрон, сигмоидная активация, даёт P(poisonous).

Сигмоидная функция активации применяется во всех слоях:

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad (1)$$

где z взвешенная сумма входов нейрона.

Сигмоида (1) сжимает выход в интервал (0, 1), что для выходного нейрона напрямую интерпретируется как вероятность принадлежности классу poisonous. Один выходной нейрон с binary cross-entropy проще двух нейронов с softmax: меньше параметров, а для бинарной задачи результат тот же.

Функция потерь, binary cross-entropy (BCE), штрафует за расхождение между предсказанной вероятностью и истинной меткой:

$$\mathcal{L} = -\frac{1}{m} \sum_{i=1}^m [y_i \log \hat{y}_i + (1 - y_i) \log (1 - \hat{y}_i)] \quad (2)$$

где m размер выборки, y_i истинная метка, $\hat{y}_i$ предсказанная вероятность.

BCE (2) минимальна, когда $\hat{y}$ совпадает с y , и резко растёт при уверенных ошибках, поэтому хорошо подходит для вероятностного выхода сигмоиды.

Обучение сети

Оптимизация: ванильный градиентный спуск, full-batch, без сторонних оптимизаторов (momentum, Adam). На каждой эпохе градиенты считаются по всей обучающей выборке (6499 примеров), веса обновляются одним шагом с learning rate 0,5. Всего 1000 эпох.

Инициализация весов, Xavier: дисперсия начальных весов подбирается так, чтобы дисперсия активаций сохранялась при прохождении через слои:

$$W \sim \mathcal{N}(0, \sigma^2), \sigma = \sqrt{\frac{2}{n_{in} + n_{out}}} \quad (3)$$

где n_{in} , n_{out} число входов и выходов слоя.

Xavier-инициализация (3) предотвращает две проблемы: при нулевых весах все нейроны слоя учат одно и то же, при слишком больших сигмоида уходит в насыщение и градиенты исчезают.

В обратном проходе для выходного слоя используется упрощение: при паре sigmoid + BCE производные функции активации и функции потерь сокращаются, и градиент по предактивации сводится к разности предсказания и метки:

$$\delta = \frac{\partial \mathcal{L}}{\partial z} = \hat{y} - y \quad (4)$$

где $\hat{y}$ выход сигмоиды, y истинная метка.

Это известный приём (4): он численно устойчив и считается одним шагом, без отдельного дифференцирования сигмоиды и логарифма. Для скрытых слоёв ошибка распространяется назад через производную сигмоиды $a(1 - a)$.

Кривая обучения

BCE-loss монотонно убывает на всём прогоне: с примерно 0,69 на старте до примерно 0,003 к 1000-й эпохе. На контрольных эпохах 0 / 200 / 400 / 600 / 800 loss принимает значения 0,6924 / 0,0490 / 0,0163 / 0,0081 / 0,0049. Full-batch градиентный спуск с $lr = 0,5$ и Xavier-инициализацией сходится устойчиво, без

скачков и расхождения, поэтому дополнительная регуляризация (weight decay, ранний останов) не требуется.




Рисунок 1 — Кривая обучения: BCE-loss по эпохам

Метрики качества

Качество оценивается на тестовой выборке (1625 примеров) при пороге отсечки 0,5. Для бинарной классификации считаются accuracy, precision, recall и F1:

$$Precision = \frac{TP}{TP + FP}, Recall = \frac{TP}{TP + FN}, F_1 = \frac{2 \cdot P \cdot R}{P + R} \quad (5)$$

где TP, FP, FN истинно-положительные, ложно-положительные и пропуски.

Метрики (5) дополняют accuracy: precision показывает долю верных среди предсказанных ядовитыми, recall долю найденных ядовитых, F1 их гармоническое среднее.

Таблица 3 — Метрики качества MLP на тестовой выборке

Метрика	Значение
Accuracy	1,000
Precision	1,000
Recall	1,000
F1-score	1,000

AUC	0,9996
-----	--------

Все 1625 тестовых примеров классифицированы правильно при пороге 0,5, поэтому accuracy, precision, recall и F1 равны единице. AUC чуть ниже единицы (0,9996), потому что предсказанные вероятности не строго 0 и 1: есть граничные случаи, и при некоторых порогах отсечки появляются единичные ложные срабатывания. AUC = 0,9996 показывает почти идеальное разделение классов.

Матрица ошибок




Рисунок 2 — Матрица ошибок на тестовой выборке

На диагонали находятся все 1625 примеров, вне диагонали нулей нет: ни одного ложно-съедобного и ни одного ложно-ядовитого. Это согласуется с тем, что один признак, odor (запах), практически детерминирует класс, поэтому датасет считается слишком простым, и сеть выходит на 100 % accuracy.

ROC-кривая и AUC

ROC-кривая строится изменением порога отсечки вероятности. По осям откладываются доля ложно-положительных (FPR) и доля истинно-положительных (TPR):

$$T P R = \frac{T P}{T P + F N}, F P R = \frac{F P}{F P + T N} \quad (6)$$

ROC (6) показывает компромисс между чувствительностью и числом ложных тревог. AUC площадь под кривой, вероятность того, что случайный ядовитый гриб получит более высокий скор $P(\text{poisonous})$, чем случайный съедобный.




Рисунок 3 — ROC-кривая на тестовой выборке (AUC = 0,9996)

Кривая прижата к левому верхнему углу, $AUC = 0,9996$. Сеть почти идеально ранжирует объекты: подавляющее большинство ядовитых грибов получает более высокий скор, чем любой съедобный.

ЗАКЛЮЧЕНИЕ

1. Многослойный персептрон реализован с нуля на numpy: прямой проход, обратное распространение ошибки и обновление весов. Архитектура [117, 64, 32, 1], сигмоидная активация во всех слоях, один выходной нейрон с binary cross-entropy.
2. Сеть обучена ванильным full-batch градиентным спуском с $lr = 0,5$, Xavier-инициализацией весов, 1000 эпох. BCE-loss монотонно убывает (примерно 0,69 до 0,003), обучение сходится устойчиво без скачков, дополнительная регуляризация не требуется.
3. На тестовой выборке: Accuracy = Precision = Recall = F1 = 1,000, AUC = 0,9996. Все 1625 примеров классифицированы верно. Высокое качество объясняется простотой датасета: признак odor почти детерминирует класс.